

TP2 – Droites de régression

Exercice 1 : estimation de D_{YX} par maximum de vraisemblance

Si n points $P_i = (x_i, y_i)$ du plan se situent au voisinage d'une droite d'équation paramétrique $y = ax + b$, il est légitime de modéliser les résidus $r_{(a,b)}(P_i) = y_i - ax_i - b$ par une loi normale centrée d'écart-type σ :

$$f_{(\sigma,a,b)}(P_i) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left\{-\frac{r_{(a,b)}(P_i)^2}{2\sigma^2}\right\} \quad (1)$$

La droite de régression de Y en X d'un tel nuage de points, notée D_{YX} , est la droite d'équation paramétrique $y = a^*x + b^*$, où a^* et b^* sont les valeurs des paramètres a et b qui maximisent la log-vraisemblance :

$$(\sigma^*, a^*, b^*) = \arg \max_{(\sigma,a,b) \in \mathbb{R}^+ \times \mathbb{R}^2} \left\{ \ln \prod_{i=1}^n f_{(\sigma,a,b)}(P_i) \right\} = \arg \min_{(\sigma,a,b) \in \mathbb{R}^+ \times \mathbb{R}^2} \sum_{i=1}^n \left\{ \ln \sigma + \frac{r_{(a,b)}(P_i)^2}{2\sigma^2} \right\} \quad (2)$$

Si l'on suppose l'écart-type du bruit σ fixé, alors le problème se simplifie :

$$(a^*, b^*) = \arg \min_{(a,b) \in \mathbb{R}^2} \sum_{i=1}^n r_{(a,b)}(P_i)^2 = \arg \min_{(a,b) \in \mathbb{R}^2} \sum_{i=1}^n (y_i - ax_i - b)^2 \quad (3)$$

La résolution de (3) par tirages aléatoires n'est pas aussi simple qu'il y paraît, car : d'une part, les inconnues a et b ne sont pas bornées ; d'autre part, a ne suit pas une loi uniforme. Néanmoins, il est facile de montrer que D_{YX} contient le centre de gravité G . On peut donc calculer les coordonnées (x_G, y_G) de G , puis centrer les données. L'équation de D_{YX} devenant $y' = a^*x'$ après changement d'origine, le problème se simplifie encore :

$$a^* = \arg \min_{a \in \mathbb{R}} \sum_{i=1}^n (y'_i - ax'_i)^2 = \tan \left\{ \arg \min_{\psi \in]-\frac{\pi}{2}, \frac{\pi}{2}[} \sum_{i=1}^n (y'_i - \tan \psi x'_i)^2 \right\} \quad (4)$$

Dans (4), la deuxième égalité vient de ce que le paramètre a d'une droite est égal à la tangente de son angle polaire ψ . La résolution de (4) peut être effectuée par tirages aléatoires de ψ selon une loi uniforme sur $] -\frac{\pi}{2}, \frac{\pi}{2}[$.

Écrivez la fonction `estimation_1`, appelée par le script `exercice_1`, permettant d'estimer la valeur de a^* .

Exercice 2 : estimation de D_{YX} par résolution d'un système linéaire

Le critère à minimiser dans (2) s'écrit $\mathcal{F}(\sigma, a, b) = n \ln \sigma + \frac{1}{2\sigma^2} \sum_{i=1}^n r_{(a,b)}(P_i)^2$. Le problème (2) peut donc également être considéré comme un problème d'optimisation différentiable. En notant $\mathcal{G}(a, b) = \sum_{i=1}^n r_{(a,b)}(P_i)^2$:

$$\nabla \mathcal{F}(\sigma, a, b) = 0 \iff \begin{cases} \nabla_{\sigma} \mathcal{F}(\sigma, a, b) = 0 \\ \nabla_{a,b} \mathcal{F}(\sigma, a, b) = 0 \end{cases} \iff \begin{cases} \sigma^2 = \frac{1}{n} \sum_{i=1}^n r_{(a,b)}(P_i)^2 \\ \nabla \mathcal{G}(a, b) = 0 \end{cases} \quad (5)$$

La première de ces équations était prévisible, puisque c'est la définition même de la variance. Quant à la deuxième équation, elle correspond à l'optimalité du critère à minimiser dans (3). Or, ce critère s'écrit aussi :

$$\mathcal{G}(a, b) = \|AX - B\|^2, \text{ où } A = \begin{bmatrix} x_1 & \cdots & x_n \\ 1 & \cdots & 1 \end{bmatrix}^T, X = [a \quad b]^T \text{ et } B = [y_1 \quad \cdots \quad y_n]^T \quad (6)$$

Minimiser $\mathcal{G}(a, b)$ revient donc à chercher une solution approchée du système linéaire $AX = B$, au sens des *moindres carrés ordinaires*. Le problème se résout en écrivant les *équations normales* $A^T A X = A^T B$, dont la solution s'écrit $X^* = (A^T A)^{-1} A^T B = A^+ B$, où $A^+ = (A^T A)^{-1} A^T$ est la *matrice pseudo-inverse* de A .

Écrivez la fonction `estimation_2`, appelée par le script `exercice_2`, permettant de comparer cette méthode d'estimation de D_{YX} avec celle de l'exercice 1. Observez l'évolution des résultats lorsque le nombre de données n ou le nombre de tests n_{tests} varient. Que se passe-t-il lorsque la droite réelle est quasi-virtuelle ?

Exercice 3 : estimation de D_{\perp} par maximum de vraisemblance

Une droite D du plan peut également être définie par son *équation cartésienne normalisée* $x \cos \theta + y \sin \theta = \rho$:

- Le paramètre θ est l'angle polaire du vecteur \vec{v} orthogonal à D , de norme 1, tel que $\theta \in]0, \pi]$ (cf. figure 1).
- En un point $P = (x_P, y_P)$ quelconque de D , on peut calculer le second paramètre $\rho = x_P \cos \theta + y_P \sin \theta$.




FIGURE 1 – Droite D_- de paramètres $(\theta_-, \rho_-) = (130, -1)$ et droite D_+ de paramètres $(\theta_+, \rho_+) = (130, 1)$.

Il semble légitime de modéliser les résidus $r_{(\theta, \rho)}(P_i) = x_i \cos \theta + y_i \sin \theta - \rho$ par une loi normale centrée :

$$f_{(\sigma, \theta, \rho)}(P_i) = \frac{1}{\sigma \sqrt{2\pi}} \exp \left\{ -\frac{r_{(\theta, \rho)}(P_i)^2}{2\sigma^2} \right\} \quad (7)$$

La *droite de régression en distance orthogonale* de ce nuage de points, notée D_{\perp} , est la droite d'équation $x \cos \theta^* + y \sin \theta^* = \rho^*$, où θ^* et ρ^* sont les valeurs des paramètres θ et ρ qui maximisent la log-vraisemblance :

$$(\sigma^*, \theta^*, \rho^*) = \arg \max_{(\sigma, \theta, \rho) \in \mathbb{R}^+ \times]0, \pi] \times \mathbb{R}} \left\{ \ln \prod_{i=1}^n f_{(\sigma, \theta, \rho)}(P_i) \right\} = \arg \min_{(\sigma, \theta, \rho) \in \mathbb{R}^+ \times]0, \pi] \times \mathbb{R}} \sum_{i=1}^n \left\{ \ln \sigma + \frac{r_{(\theta, \rho)}(P_i)^2}{2\sigma^2} \right\} \quad (8)$$

En supposant σ fixé, et sachant que la droite de régression D_{\perp} contient elle aussi le centre de gravité G , la résolution du problème (8) est en tout point analogue à celle du problème (2). Par analogie avec (4) :

$$\theta^* = \arg \min_{\theta \in]0, \pi]} \sum_{i=1}^n (x'_i \cos \theta + y'_i \sin \theta)^2 \quad (9)$$

Écrivez la fonction `estimation_3`, appelée par `exercice_3`, permettant d'estimer θ^* par ce procédé.

Exercice 4 : estimation de D_{\perp} par résolution d'un système linéaire

Le critère $\mathcal{I}(\theta) = \sum_{i=1}^n (x'_i \cos \theta + y'_i \sin \theta)^2$ à minimiser dans (9) s'appelle l'*inertie*. Il s'écrit également :

$$\mathcal{I}(\theta) = \|CY\|^2, \text{ où } C = \begin{bmatrix} x'_1 & \cdots & x'_n \\ y'_1 & \cdots & y'_n \end{bmatrix}^T \text{ et } Y = [\cos \theta \quad \sin \theta]^T \quad (10)$$

Or, la solution approchée du système linéaire $CY = O$, au sens des moindres carrés ordinaires, vaut $C^+O = O$. Pour éviter cette solution, on impose la contrainte $\|Y\| = 1$ (résolution approchée au sens des *moindres carrés totaux*). Ce nouveau problème se résout en introduisant le *lagrangien* $\mathcal{L}(Y, \lambda) = \|CY\|^2 + \lambda(1 - \|Y\|^2)$, où λ constitue un *multiplicateur de Lagrange*. La condition d'optimalité de \mathcal{L} s'écrit :

$$\nabla \mathcal{L}(Y, \lambda) = 0 \iff \begin{cases} \nabla_Y \mathcal{L}(Y, \lambda) = 0 \\ \nabla_{\lambda} \mathcal{L}(Y, \lambda) = 0 \end{cases} \iff \begin{cases} C^T CY = \lambda Y \\ \|Y\| = 1 \end{cases} \quad (11)$$

Sachant que $C^T C$ est symétrique réelle, cette matrice admet une base orthonormée de vecteurs propres. De plus, comme $C^T C$ est *semi-définie positive*, ses valeurs propres sont positives ou nulles. Le minimiseur de $\mathcal{I}(\theta)$ de norme 1, noté Y^* , est donc un des deux vecteurs propres associés à la plus petite valeur propre de $C^T C$. En effet, pour un vecteur propre Y_p de norme 1, associé à la valeur propre λ_p : $\|CY_p\|^2 = Y_p^T C^T CY_p = \lambda_p Y_p^T Y_p = \lambda_p$.

Écrivez la fonction `estimation_4`, appelée par `exercice_4`, permettant de comparer cette méthode d'estimation de D_{\perp} à celle de l'exercice 3. Observez l'évolution des résultats en fonction de n et de n_{tests} .